

UNIVERSIDADE FEDERAL DE LAVRAS

Disciplina: Engenharia de Software

Prospecção Tecnológica

Machine Learning Aplicado à Previsão de Volatilidade de Preços de Combustíveis

Autor: Caio Teixeira Ladeira

2026/1

Link do Vídeo: [Clique aqui](#)

Repositório GitHub: [Clique aqui](#)

Sumário

Sumário	2
1. Introdução e Contextualização	2
1.1 Definição do Objeto de Estudo	2
1.2 Motivação	2
1.3 Problema que a Abordagem Resolve	2
2. Fundamentação Teórica	3
2.1 Histórico e Evolução	3
2.2 Arquitetura e Funcionamento	3
2.2.1 Pipeline Geral	3
2.2.2 Random Forest	3
2.2.3 Engenharia de Features	4
2.2.4 Definição da Variável Alvo	4
2.3 Conceitos-Chave	4
3. Análise Comparativa	6
3.1 Estado da Arte vs. Alternativas	6
3.1.1 Modelos Econométricos Tradicionais (ARIMA, GARCH)	6
3.1.2 Gradient Boosting (XGBoost, LightGBM)	6
3.1.3 Redes Neurais Recorrentes (LSTM)	6
3.2 Quadro Comparativo	6
3.3 Vantagens e Limitações do Modelo Escolhido	7
4. Aplicação Prática — Prova de Conceito (PoC)	8
4.1 Ambiente de Desenvolvimento	8
4.2 Demonstração do Código	8
4.2.1 Tratamento de Nulos	8
4.2.2 Engenharia de Features	8
4.2.3 Definição do Alvo e Split Temporal	9
4.2.4 Balanceamento e Treinamento	9
4.3 Relato de Experiência	9
5. Perspectivas Futuras e Mercado	11
5.1 Tendências	11
5.2 Adoção na Indústria	11
6. Conclusão e Referências	12
6.1 Síntese Crítica	12
6.2 Referências	12

1. Introdução e Contextualização

1.1 Definição do Objeto de Estudo

Este trabalho investiga a aplicação de técnicas de machine learning — especificamente classificação binária com Random Forest — sobre dados históricos de preços de combustíveis coletados pela ANP (Agência Nacional do Petróleo, Gás Natural e Biocombustíveis) com o objetivo de prever semanas de alta volatilidade de preços do Óleo Diesel S10 nos estados brasileiros.

O Diesel S10 é o combustível de referência para o transporte de cargas e passageiros no Brasil. Sua variação de preço impacta diretamente custos logísticos, inflação e planejamento empresarial. A capacidade de antecipar semanas de alta oscilação tem valor prático imediato para transportadoras, distribuidoras e gestores de frotas.

1.2 Motivação

O preço do Diesel S10 no Brasil é influenciado por múltiplos fatores simultâneos: cotação internacional do petróleo (Brent), taxa de câmbio USD/BRL, política de preços da Petrobras, impostos estaduais (ICMS) e logística de distribuição. Essa combinação de variáveis torna o preço altamente não-linear e difícil de prever com métodos estatísticos tradicionais.

Modelos de machine learning, por sua capacidade de capturar relações não-lineares e interações entre variáveis, representam uma abordagem natural para esse problema. Em particular, a formulação como classificação binária — "esta semana será de alta volatilidade ou não?" — é mais robusta para fins práticos do que tentar prever o valor exato do preço futuro.

1.3 Problema que a Abordagem Resolve

O problema central é a falta de antecipação de choques de preços. Sem um sistema de alerta precoce, empresas de transporte e logística reagem de forma reativa a aumentos expressivos de preço, sem tempo para ajustar contratos, estoques ou operações.

A abordagem proposta não substitui a análise fundamentalista (Brent, câmbio), mas funciona como um complemento baseado em padrões históricos internos da série de preços: se o mercado já deu sinais de agitação nas últimas semanas, o modelo identifica isso e emite um alerta.

2. Fundamentação Teórica

2.1 Histórico e Evolução

O uso de machine learning para previsão de séries temporais de commodities tem raízes nos anos 1990, quando redes neurais artificiais começaram a ser aplicadas a previsões de preços de petróleo. Naquela época, as limitações computacionais e a escassez de dados históricos digitalizados restringiam os experimentos a modelos simples.

Com o advento de bases de dados públicas e o aumento da capacidade computacional nos anos 2000, métodos baseados em árvores de decisão e, posteriormente, ensembles como Random Forest (Breiman, 2001) e Gradient Boosting passaram a dominar a literatura de previsão de commodities. O Random Forest, em particular, consolidou-se como o método de referência para classificação tabular por sua robustez, interpretabilidade relativa e bom desempenho sem ajuste fino extensivo.

No contexto brasileiro, a ANP disponibiliza dados semanais de preços de combustíveis desde 2004, o que permite construir séries históricas longas o suficiente para treinar modelos supervisionados.

2.2 Arquitetura e Funcionamento

2.2.1 Pipeline Geral

O pipeline implementado segue seis etapas sequenciais:

- Carregamento e limpeza dos dados brutos da ANP (remoção de colunas com baixa cobertura, tratamento de valores nulos, conversão de tipos).
- Filtragem para Diesel S10 no período 2021-presente.
- Análise exploratória (EDA) para compreender distribuição de preços, sazonalidade e heterogeneidade regional.
- Engenharia de features: cálculo de variação semanal, médias móveis, desvio padrão móvel e lags.
- Definição da variável alvo binária com limiar P90 calculado exclusivamente no conjunto de treino.
- Treinamento de Random Forest com oversampling manual e avaliação por métricas de classificação.

2.2.2 Random Forest

Um Random Forest é um ensemble de árvores de decisão treinadas de forma independente sobre subamostras aleatórias dos dados (bagging) e com subconjuntos aleatórios das features em cada divisão. A predição final é a votação majoritária entre todas as árvores.

As propriedades que tornam o Random Forest adequado para este problema são:

- Não assume linearidade entre features e alvo — essencial para séries de preços de commodities.

- Produz estimativas de importância de features, permitindo interpretar quais variáveis mais contribuem para a predição.
- É robusto a outliers e a features com escalas diferentes (não requer normalização).
- Tende a não sofrer overfitting severo quando os hiperparâmetros de regularização (max_depth, min_samples_leaf) são configurados.

2.2.3 Engenharia de Features

As features foram construídas de forma a capturar padrões relevantes para a volatilidade:

- VARIACAO_SEMANAL: variação percentual semana a semana do preço, calculada dentro de cada estado para evitar artefatos de fronteira.
- MEDIA_MOVE_4_SEMANAS: tendência de curto prazo — preços em trajetória de alta tendem a continuar subindo.
- VOLATILIDADE_4_SEMANAS: desvio padrão das variações recentes — mercado já agitado tende a permanecer agitado.
- LAG_1_SEMANA e LAG_2_SEMANAS: inércia e ciclos de ajuste de preços.
- MES e ANO: sazonalidade e tendência de longo prazo.

2.2.4 Definição da Variável Alvo

A variável alvo ALTA_VOLATILIDADE é binária: vale 1 quando a variação absoluta semanal do preço supera o percentil 90 (P90) das variações do conjunto de treino, e 0 caso contrário. O uso do P90 garante que apenas semanas genuinamente atípicas sejam rotuladas como alta volatilidade, resultando em aproximadamente 10% de positivos — proporção adequada para um problema de classificação de eventos raros.

O limiar é calculado exclusivamente sobre o treino para evitar data leakage: se o P90 fosse calculado sobre todo o dataset, o modelo estaria indiretamente "vendo" o futuro ao aprender o padrão.

2.3 Conceitos-Chave

Termo	Definição
Data Leakage	Uso indevido de informação do futuro durante o treinamento do modelo, inflando artificialmente o desempenho avaliado.
Split Temporal	Divisão treino/teste respeitando a ordem cronológica, sem embaralhamento aleatório.
Oversampling	Técnica de balanceamento que replica registros da classe minoritária para reduzir o viés do modelo em direção à classe majoritária.
Percentil 90 (P90)	Valor abaixo do qual se encontram 90% das observações. Usado como limiar para definir o que é "alta volatilidade".

Termo	Definição
Recall	Proporção de positivos reais corretamente identificados pelo modelo. Métrica principal para problemas com classes desbalanceadas.
Coeficiente de Variação	Desvio padrão dividido pela média, expresso em percentual. Mede dispersão relativa ao nível de preço.

3. Análise Comparativa

3.1 Estado da Arte vs. Alternativas

Para o problema de previsão de volatilidade de preços de commodities em séries temporais, existem três abordagens principais que competem com o Random Forest utilizado neste projeto:

3.1.1 Modelos Econométricos Tradicionais (ARIMA, GARCH)

Os modelos ARIMA (AutoRegressive Integrated Moving Average) e GARCH (Generalized AutoRegressive Conditional Heteroskedasticity) são a abordagem clássica para séries temporais financeiras e de commodities. O GARCH, em particular, foi desenvolvido especificamente para modelar volatilidade variante no tempo.

Vantagem: são interpretáveis, têm fundamento estatístico sólido e requerem poucos dados. Limitação: assumem relações lineares e homogeneidade da série, o que não se sustenta quando há quebras estruturais (como os choques de 2022) ou quando o comportamento varia por estado.

3.1.2 Gradient Boosting (XGBoost, LightGBM)

Os algoritmos de gradient boosting constroem árvores sequencialmente, onde cada nova árvore corrige os erros da anterior. Em benchmarks de dados tabulares, XGBoost e LightGBM consistentemente superam o Random Forest em acurácia.

Vantagem: maior capacidade preditiva para dados tabulares. Limitação: mais sensíveis a hiperparâmetros, maior risco de overfitting sem ajuste cuidadoso, e mais lentos para treinar. Para uma PoC de exploração, o Random Forest é mais adequado por sua robustez com configurações padrão.

3.1.3 Redes Neurais Recorrentes (LSTM)

LSTMs (Long Short-Term Memory) são redes neurais projetadas para capturar dependências de longo prazo em sequências. São o estado da arte em previsão de séries temporais longas.

Vantagem: capturam padrões temporais complexos que árvores de decisão não conseguem. Limitação: requerem muito mais dados, são computacionalmente custosas, difíceis de interpretar e sensíveis a hiperparâmetros. Para o volume de dados da ANP por estado (~200 semanas), o LSTM não é adequado sem regularização intensiva.

3.2 Quadro Comparativo

Critério	Random Forest	GARCH	XGBoost	LSTM
Interpetabilidade	Média	Alta	Média	Baixa
Dados necessários	Moderado	Baixo	Moderado	Alto
Não-linearidade	Sim	Não	Sim	Sim

Critério	Random Forest	GARCH	XGBoost	LSTM
Dependências longas	Não	Parcial	Não	Sim
Facilidade de uso	Alta	Média	Média	Baixa
Adequação ao problema	Boa	Parcial	Boa	Limitada*

*Limitada pelo volume de dados disponível por estado (~200 semanas).

3.3 Vantagens e Limitações do Modelo Escolhido

O Random Forest se mostrou adequado para este projeto pelos seguintes motivos: a base de dados tem dimensão moderada (sem necessidade de grandes volumes); as features são tabulares e heterogêneas (preços, datas, desvios); e o objetivo era demonstrar o pipeline completo com um modelo interpretável, não maximizar performance.

As principais limitações identificadas são: ausência de variáveis externas com alto poder explicativo (Brent, câmbio); incapacidade do modelo de capturar dependências de longo prazo (ciclos anuais, por exemplo); e validação feita com um único split temporal, quando o ideal seria TimeSeriesSplit com múltiplas janelas.

4. Aplicação Prática — Prova de Conceito (PoC)

4.1 Ambiente de Desenvolvimento

Componente	Versão / Detalhe
Python	3.10
pandas	2.x
numpy	1.x
scikit-learn	1.x
matplotlib / seaborn	3.x
Jupyter Notebook	Ambiente de execução
Dados	ANP — Série histórica semanal de preços de combustíveis por estado (desde 2013)

4.2 Demonstração do Código

4.2.1 Tratamento de Nulos

O primeiro passo crítico da limpeza é remover colunas com cobertura insuficiente e linhas sem dados nas colunas centrais do pipeline:

```
LIMIAR_NULOS = 0.50
colunas_para_dropar = [col for col in df.columns
                        if df[col].isna().sum() / len(df) > LIMIAR_NULOS]
df = df.drop(columns=colunas_para_dropar)
df = df.dropna(subset=["PREÇO MÉDIO REVENDA", "DATA INICIAL"], how="any")
```

A remoção de colunas com mais de 50% de nulos garante que features como MARGEM MÉDIA REVENDA, que têm cobertura irregular na base da ANP, não contaminem o modelo com informação espúria.

4.2.2 Engenharia de Features

O cálculo das features é feito dentro de cada estado para evitar que a fronteira entre registros de estados diferentes gere valores incorretos:

```
df_diesel["VARIACAO_SEMANAL"] = (
    df_diesel.groupby("ESTADO")["PREÇO MÉDIO REVENDA"].pct_change()
)
df_diesel["MEDIA_MOVEL_4_SEMANAS"] = (
    df_diesel.groupby("ESTADO")["PREÇO MÉDIO REVENDA"]
    .transform(lambda x: x.rolling(4).mean())
)
df_diesel["VOLATILIDADE_4_SEMANAS"] = (
    df_diesel.groupby("ESTADO")["VARIACAO_SEMANAL"]
    .transform(lambda x: x.rolling(4).std())
)
```

4.2.3 Definição do Alvo e Split Temporal

O limiar é calculado exclusivamente sobre o treino para evitar data leakage:

```
data_corte = df_diesel["DATA INICIAL"].quantile(0.8)
mask_train = df_diesel["DATA INICIAL"] <= data_corte

limite_volatilidade = (
    df_diesel.loc[mask_train, "VARIACAO_SEMANAL"].abs().quantile(0.90)
)
df_diesel["ALTA_VOLATILIDADE"] = (
    df_diesel["VARIACAO_SEMANAL"].abs() > limite_volatilidade
).astype(int)
```

Com os dados reais da ANP para o período 2021-2026, o limiar P90 resultou em aproximadamente 0.026 (2,6% de variação semanal), com 9,4% dos registros classificados como alta volatilidade.

4.2.4 Balanceamento e Treinamento

O oversampling manual eleva a classe minoritária para um terço do treino, sem comprometer a distribuição real do conjunto de teste:

```
X_min_up, y_min_up = resample(
    X_train_min, y_train_min,
    replace=True,
    n_samples=len(X_train_maj) // 2,
    random_state=42,
)
modelo = RandomForestClassifier(
    n_estimators=200, max_depth=10, min_samples_leaf=5, random_state=42
)
modelo.fit(X_train_bal, y_train_bal)
```

4.3 Relato de Experiência

A configuração do ambiente foi direta, dado que todas as bibliotecas utilizadas são amplamente mantidas e disponíveis via pip. A principal dificuldade técnica foi conceitual: entender a diferença entre calcular o limiar sobre todos os dados versus apenas sobre o treino. Calcular sobre todos os dados inflaria artificialmente as métricas porque o modelo estaria aprendendo um padrão definido com base nos próprios dados de teste — o que não reflete o comportamento real de um sistema em produção.

A segunda dificuldade foi a definição do split temporal. O DataFrame contém registros de múltiplos estados misturados, então ordenar por linha e pegar os primeiros 80% seria incorreto — a data de corte precisa ser calculada sobre o domínio temporal, não sobre o índice do DataFrame.

O uso de IA (Claude) foi relevante para identificar inconsistências entre o que o código fazia e o que a documentação declarava — por exemplo, a variável ALTA_VOLATILIDADE_FUTURA estava documentada como alvo mas o modelo

treinava sobre ALTA_VOLATILIDADE. Esse tipo de inconsistência sutil é difícil de perceber sem uma revisão estruturada.

5. Perspectivas Futuras e Mercado

5.1 Tendências

A principal tendência nesse campo é a incorporação de dados externos ao modelo. Variáveis macroeconômicas como o preço do petróleo Brent, a taxa de câmbio USD/BRL e índices de inflação têm alto poder explicativo sobre o preço do diesel e ainda não foram incluídas na PoC. A literatura recente aponta que modelos híbridos — que combinam features de séries temporais internas com variáveis macroeconômicas exógenas — superam consistentemente modelos que usam apenas o histórico de preços.

Outra tendência relevante é a substituição do Random Forest por métodos de gradient boosting (XGBoost, LightGBM) em pipelines de produção, dada a superioridade desses métodos em benchmarks de dados tabulares. Para séries com padrões de longo prazo mais complexos, modelos baseados em transformers (como o PatchTST) estão emergindo como alternativa às LSTMs.

No contexto regulatório brasileiro, a política de preços da Petrobras passou por mudanças significativas em 2022-2023, o que afeta a estrutura da série temporal. Modelos que incorporam variáveis de regime (se a política de paridade internacional está ativa ou não) tendem a ser mais robustos a essas quebras estruturais.

5.2 Adoção na Indústria

A previsão de volatilidade de commodities é uma área consolidada na indústria financeira e de energia. Tradings de energia, fundos de commodities e distribuidoras de combustível utilizam modelos preditivos para decisões de hedge, estoques e contratos de longo prazo.

No Brasil, empresas como Vibra Energia (ex-BR Distribuidora) e Raízen operam com áreas de analytics e ciência de dados voltadas a otimização de preços e logística de abastecimento. Startups de logística como Buser e Intelipost também investem em modelos de custo de frete que incorporam previsões de preço de combustível.

Do ponto de vista de mercado de trabalho, a combinação de conhecimentos em ciência de dados, séries temporais e domínio de logística/energia é valorizada em posições de Data Scientist e ML Engineer em empresas de energia, logística e consultorias focadas nesses setores.

6. Conclusão e Referências

6.1 Síntese Crítica

O projeto demonstrou que é viável construir um classificador de volatilidade de preços de Diesel S10 com acurácia razoável utilizando apenas dados históricos da ANP e features de engenharia simples. O Random Forest, com oversampling manual e split temporal correto, produz um modelo que detecta uma proporção significativa das semanas de alta volatilidade sem uma taxa excessiva de falsos positivos.

No entanto, o modelo tem limitações claras que precisam ser reconhecidas: ele é reativo — só consegue identificar semanas de alta volatilidade que se assemelham a padrões já observados no treino. Choques exógenos sem precedente (como o início de um conflito geopolítico ou uma mudança abrupta de política de preços) não seriam capturados adequadamente. Para isso, variáveis externas e mecanismos de detecção de quebra estrutural seriam necessários.

Do ponto de vista metodológico, a principal contribuição do projeto foi demonstrar a aplicação correta de um pipeline de machine learning para séries temporais com dados de múltiplas entidades (estados), incluindo os cuidados necessários com data leakage, split temporal e balanceamento de classes. Esses cuidados são frequentemente negligenciados em implementações iniciais e comprometem a validade dos resultados.

A tecnologia é uma "aposta segura" como componente de um sistema maior de suporte à decisão, mas não deve ser usada isoladamente como único insumo para decisões de alto impacto. A combinação com análise fundamentalista e monitoramento de variáveis exógenas aumentaria substancialmente a utilidade do modelo.

6.2 Referências

BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5-32, 2001.

AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS (ANP). Levantamento de Preços de Combustíveis — Série Histórica. Disponível em: <https://www.gov.br/anp/pt-br/assuntos/precos-e-defesa-da-concorrenca/precos/precos-revenda-e-de-distribuicao-combustiveis/serie-historica-do-levantamento-de-precos>. Acesso em: jun. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

BOLLERSLEV, T. Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*, v. 31, n. 3, p. 307-327, 1986.

CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.

McKINNEY, W. Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, p. 51-56, 2010.